GCS访问日志配置和查询

Author: eugeneyu@google.com

概述

- 一、配置和使用GCS审计日志
- 二、配置和使用GCS Usage Logs
- 三、将GCS Usage Logs导入到BigQuery进行结构化存储和查询

附录

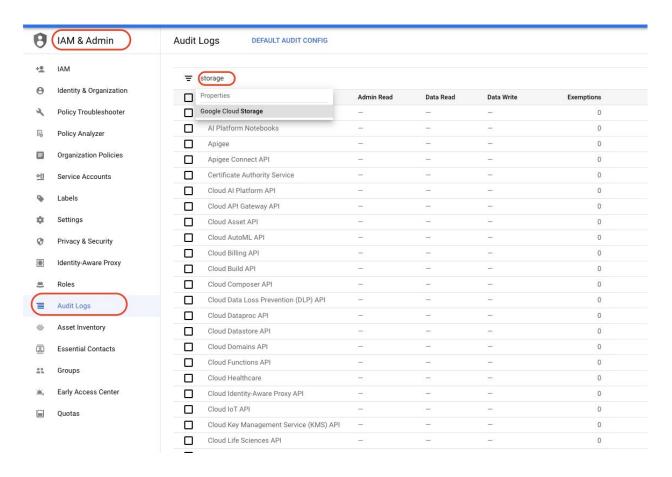
概述

Google Cloud Storage (GCS) 是谷歌云的对象存储,适用于长期存储视频、图片、日志等非结构化内容文件。如果涉及到海量用户内容上传和下载,那么追踪对象访问记录,进行统计分析和错误排查,会是一个常见的需求。这时可以利用GCS的访问日志来满足需求。下面介绍开通和使用GCS访问日志的一些方法。

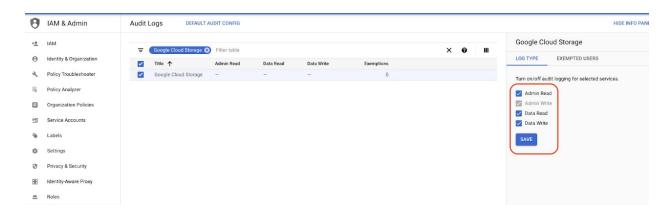
一、配置和使用GCS审计日志

谷歌云很多产品都提供审计日志,帮助用户查询"谁,在何地,做了什么"的问题。GCS的审计日志包含Admin Activity Logs和Data Access Logs。我们可以用Data Access Logs审计日志来查看不同用户对GCS上对象文件的访问操作。

为了节省用户费用,GCS的审计日志默认是关闭的。可以在控制台IAM菜单的Audit Logs查看其状态,并将其打开。



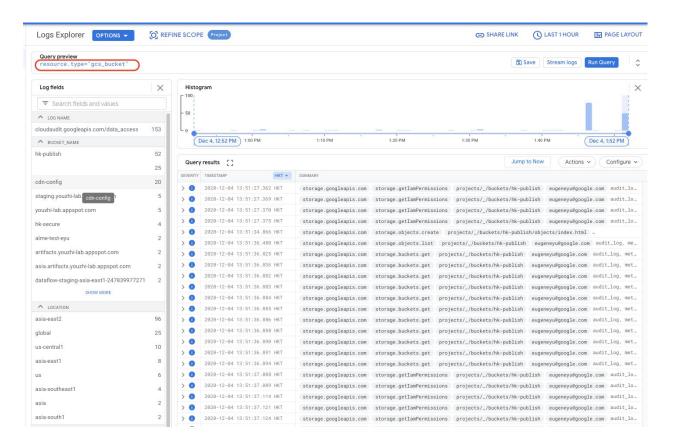
如果Google Cloud Stroage的各个审计日志项都是"-"状态,说明没有打开。可以选中后在右侧配置面板打开各项日志,并保存配置。



审计日志打开后, 其状态应该如下所示。



审计日志打开后,对象的访问日志会实时导入到谷歌云日志服务。可以在日志服务的Log Explorer中进行查看。注意在查询表达式栏中输入'resource.type="gcs_bucket"'。



在列出的对象访问日志中,可以查看到每次访问的详细信息。比如展开一个访问记录,可以看到访问的操作是创建或下载,访问的用户账号,访问的对象URI,访问的结果等等。

```
v 1 2028-12-04 13:51:34.866 HKT storage.googleapis.com storage.objects.create projects/_/buckets/hk-publish/objects/index.html
                                  eugeneyu@google.com audit_log, method: "storage.objects.create", principal_email: "______@google.com"
                                                              @type: "type.googleapis.com/google.cloud.audit.AuditLog"
   ▼ authenticationInfo: {
      principalEmail: "google.com"
   ▶ requestMetadata: {4}
     serviceName: "storage.googleapis.com"
     methodName: "storage.objects.create"
   ▼ authorizationInfo: [
    ▶ 0: {4}
    ▶ 1: {4}
     resourceName: "projects/_/buckets/hk-publish/objects/index.html"
   ▶ serviceData: {2}
   ▶ resourceLocation: {1}
    insertId: "o5ec8we41d36"
  ▼ resource: {
    type: "gcs_bucket"
   ▶ labels: {3}
    timestamp: "2020-12-04T05:51:34.866591414Z"
    severity: "INFO"
    logName: "projects/youzhi-lab/logs/cloudaudit.googleapis.com%2Fdata_access"
    receiveTimestamp: "2020-12-04T05:51:35.212382786Z"
```

需要注意的是,Storage Audit Log 审计日志开启后,可以看到授权实名用户访问的记录。但是<mark>看</mark> 不到匿名用户的访问记录,和通过谷歌云CDN的访问记录。

比如用下面两种方式访问对象,不会产生日志。

1. 直接用对象链接下载

```
$ curl https://storage.googleapis.com/hk-publish/index.html
```

2. 通过CDN下载

```
$ curl http://35.244.150.103/index.html
```

如果需要查看匿名用户的访问记录,那么需要使用GCS的Usage Logs。

二、配置和使用GCS Usage Logs

GCS的Usage Logs不像审计日志一样自动导入到日志服务,而是会导出到对象存储。所以首先需要创建一个存放日志的对象存储桶。

gsutil mb -1 ASIA-EAST2 gs://youzhi-lab-logs-bucket

给Usage Logs服务的服务账号提供写访问日志存储桶的权限。

gsutil iam ch group:cloud-storage-analytics@google.com:legacyBucketWriter gs://youzhi-lab-logs-bucket

打开目标桶的Usage Logs,并将其日志输出桶设为刚建好的日志存储桶。同时也可以设置一个日志文件前缀,相当于目录。

gsutil logging set on -b gs://youzhi-lab-logs-bucket -o
hk-publish-access-log/ gs://hk-publish

确认目标桶的日志已经打开。

gsutil logging get gs://hk-publish

应该看到类似如下输出。

youzhi-lab-logs-bucket

{"logBucket": "youzhi-lab-logs-bucket", "logObjectPrefix": "hk-publish-access-log/"}

日志打开之后, GCS日志服务会每小时一次把目标桶的访问日志输出到日志存储桶, 生成日志文件。可以等1-2小时后到日志存储桶查看。

OR IFCTS CONFIGURATION RETENTION LIFECYCLE PERMISSIONS Buckets > youzhi-lab-logs-bucket > hk-publish-access-log □ UPLOAD FILES UPLOAD FOLDER CREATE FOLDER MANAGE HOLDS DOWNLOAD DELETE Sort and filter ▼ Filter Filter objects and folders 0 or faster performance, select Filter by name prefix only from the filtering menu. _usage_2020_12_07_02_00_00_04a229c0feedd60cb4_v0 Size Created time ② ↑ Storage class _usage_2020_12_07_02_00_00_04a229c0feedd60cb4 459 B application/octet-stream Dec 7, 2020, 11:09:... Standard 968 B application/octet-stream Dec 7, 2020, 11:10:... Standard _usage_2020_12_07_02_00_00_01a229c0feedd60cb4 522 B application/octet-stream Dec 7, 2020, 11:10:... Standard 504 B Dec 7, 2020, 11:10:... Standard _usage_2020_12_07_02_00_00_07a229c0feedd60cb4 application/octet-stream

但是手工下载和查看日志存储桶中的众多文件非常耗时,也不方便。我们建议将日志再转存到谷歌云数据仓库BigQuery,方便使用SQL进行查询,也可以接入其它数据分析工具和展示报表。

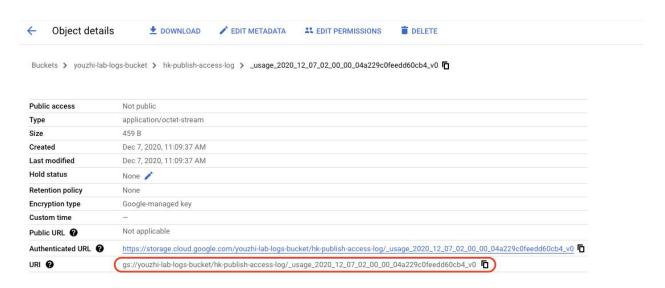
三、将GCS Usage Logs导入到BigQuery进行结构化存储和查询

首先创建一个BigQuery数据集,用来存放GCS日志。下面操作使用BigQuery的命令行工具。但也可以在控制台操作。

命令行工具的安装使用可以参考此文档。

bq mk --location asia-east2 storage_logs

下面要用官方提供的schema文件创建一个数据表,并导入一个日志文件。可以到日志文件存储桶, 拷贝一个Usage Logs日志文件的URI。

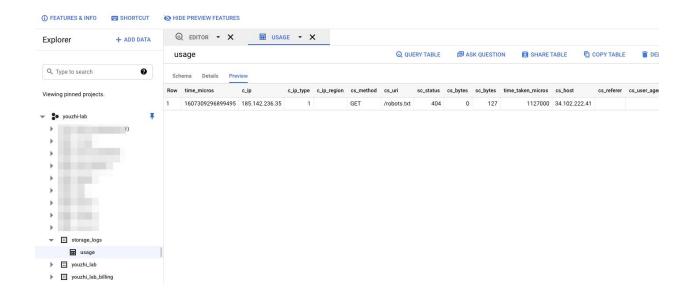


下载Schema文件并导入一个日志文件。导入任务会根据Schema文件自动创建一个表。

```
wget http://storage.googleapis.com/pub/cloud_storage_usage_schema_v0.json

bq load --skip_leading_rows=1 storage_logs.usage \
gs://youzhi-lab-logs-bucket/hk-publish-access-log/_usage_2020_12_07_02_00_0
0_04a229c0feedd60cb4_v0 \
./cloud_storage_usage_schema_v0.json
```

导入完成后,可以到BigQuery控制台查看表中的数据。



上述操作成功后、删除导入的日志文件、并导入剩余的其它日志文件。

```
gsutil rm
gs://youzhi-lab-logs-bucket/hk-publish-access-log/_usage_2020_12_07_02_00_0
0_04a229c0feedd60cb4_v0

bq load --skip_leading_rows=1 storage_logs.usage \
"gs://youzhi-lab-logs-bucket/hk-publish-access-log/_usage_2020*" \
./cloud_storage_usage_schema_v0.json
```

导入完成后会看到如下提示。

```
[eugeneyu:~/Downloads]$ bq load --skip_leading_rows=1 storage_logs.usage \
"gs://youzhi-lab-logs-bucket/hk-publish-access-log/_usage_2020*" \
./cloud_storage_usage_schema_v0.json
Waiting on bqjob_r23001ebc1e29531a_0000017641d32584_1 ... (0s) Current status: DONE
```

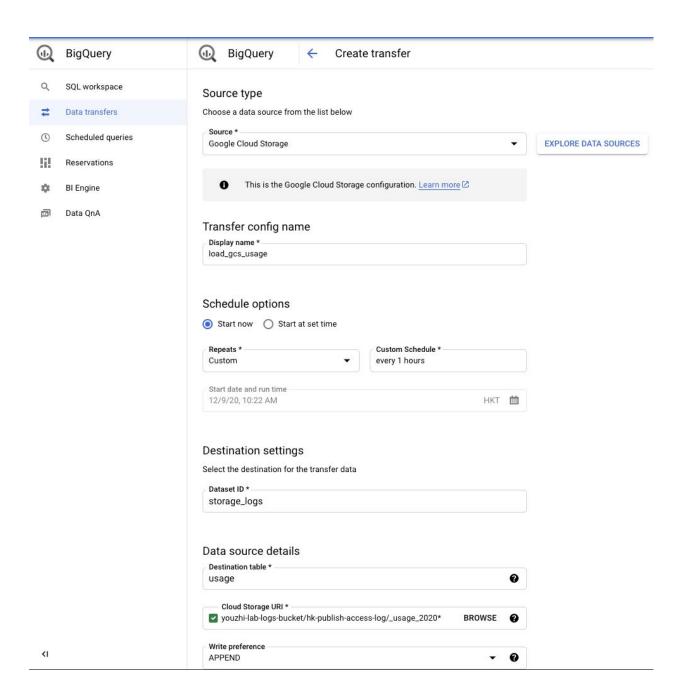
可以在BigQuery中用对象名搜索特定对象的访问记录列表。

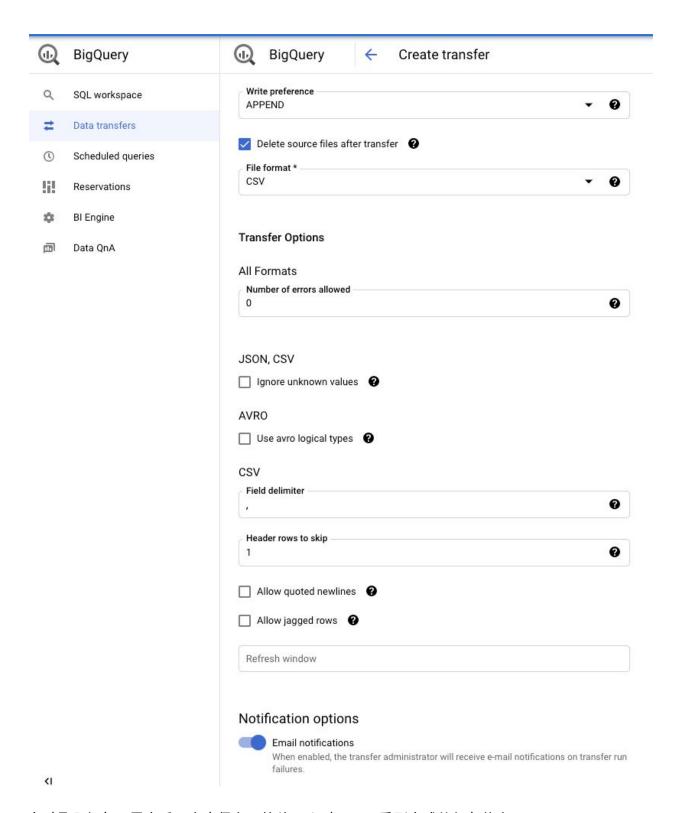


以上是用命令行对存量日志做批量导入。对增量日志,也可以用定时导入任务来自动化导入。 首先删除之前已经导入过的日志。

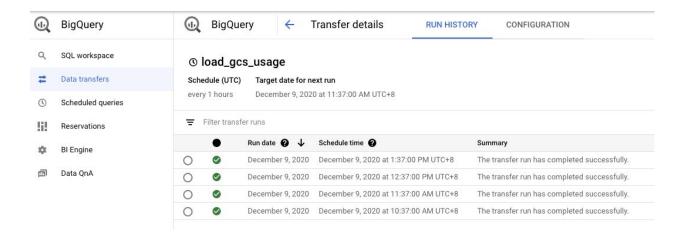
gsutil rm "gs://youzhi-lab-logs-bucket/hk-publish-access-log/_usage_2020*"

然后在BigQuery的Data Transfers菜单创建一个导入任务。进行如下配置。注意选择的频率是每小时一次——这是自动任务可以执行的最高频率。另外,写入模式为Append,追加写入。





定时导入任务配置完后,点击保存。等待几小时,可以看到完成的任务状态。



之后,可以在BigQuery里随时查看GCS的对象访问记录,也可以用程序执行查询,根据结果触发后续操作。

不过需要注意,通过gsutil工具,或者控制台做的上传、修改、下载等操作,由于属于审计日志范畴,<mark>不会在</mark>Usage Log里记录。这些日志需要通过第一节所介绍的审计日志查看方式来查询。

附录

- [1] Cloud Audit Logs with Cloud Storage
- [2] Usage logs & storage logs
- [3] Using the bg command-line tool