# 在GCP创建AWS RDS实例的远程备份并 作为BigQuery外表查询

本文介绍如何在谷歌云配置AWS RDS MySQL实例的同步副本,并在谷歌云BigQuery数据仓库使用Federated Query联合查询来查询来自于RDS的数据,并与数据仓库里的数据做合并查询。这样做可以扩展BigQuery查询的数据来源,丰富使用场景,简化数据导出导入过程。

更新RDS实例参数

创建同步复制数据库实例

<u>在BigQuery中执行联合查询</u>

## 更新RDS实例参数

当在谷歌云创建外部源数据库的同步副本时,对于外部源数据库有如下要求[1]。

- 正在运行 MySQL Community Edition 版本 5.6 或 5.7。
- 已启用二进制日志。了解详情。
- 将二进制日志保留足够长的时间,让副本能完成导入。 一般来说,一周的时间应该足够了。详细了解如何设置二进制日志保留政策。
- 使用基于行的二进制日志记录。 了解详情。
- 启用 GTID 并强制执行 GTID 一致性。 详细了解 GTID。请查看强制执行 GTID 一致性的选项。
- 所有表(系统数据库中的表除外)都使用 InnoDB 存储引擎。 详细了解 InnoDB。 详细了解如何转换为 InnoDB。
- 具有 REPLICATION\_SLAVE 权限的 MySQL 用户帐号。 将此帐号配置为接受来自任何位置 (host = %) 的连接。您可以在后面的步骤中限制 此用户的访问权限。您不应将此用户帐号用于复制以外的任何其他目的。 详细了解权限。详细了解用户帐号。
- 可在外部访问的 IPv4 地址和 TCP 端口。

请检查您的RDS示例满足上述要求。下面的步骤作为示例介绍如何更新RDS实例满足启用GTID和创建有REPLICATION\_SLAVE权限的用户账号的要求。

首次要为已有的RDS实例配置开启GTID复制,需要实例为MySQL 5.7.23或以上版本。目前(2020年3月)的默认版本一般为5.7.22,所以大部分已有实例需要进行升级。可以在AWS RDS控制台查看实例的MySQL版本。

### Configuration

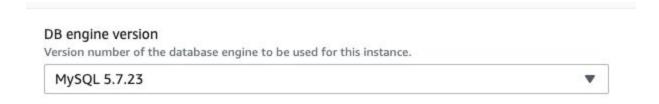
DB instance id

rds-sin-1

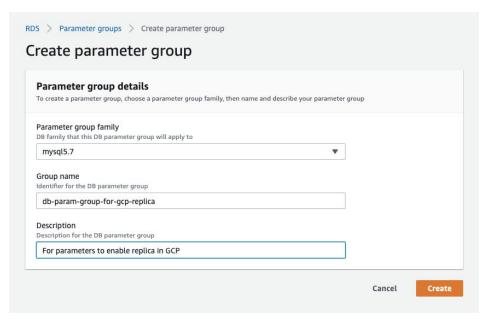
Engine version

5.7.22

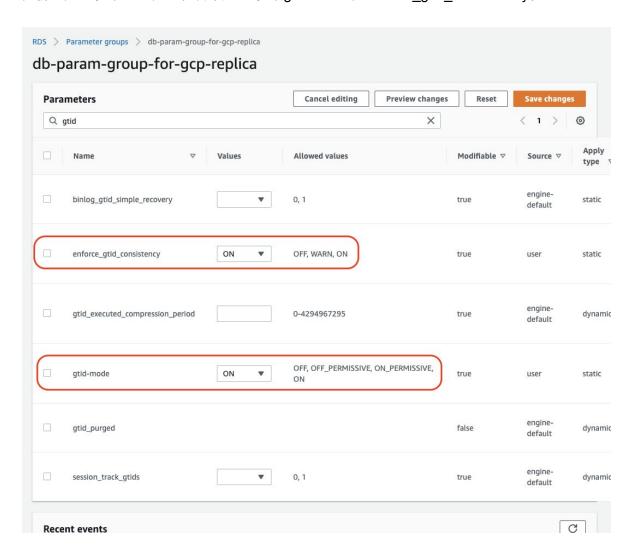
在控制台对实例进行修改,选择5.7.23或以上的版本(提前对数据做好备份)。



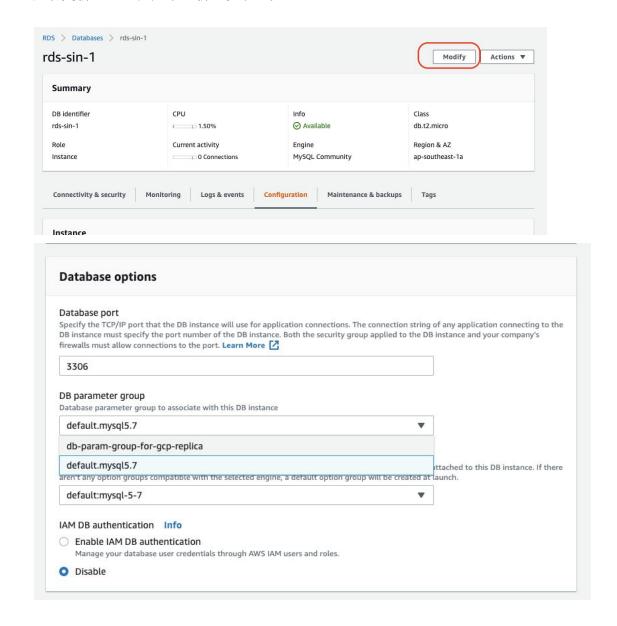
RDS默认的Parameter Group参数组没有开启GTID,需要创建单独的参数组来开启(除非已经有了非默认的参数组)。如下图。



在新创建的参数组里,配置开启两个参数gtid-mode和enforce\_gtid\_consistency。



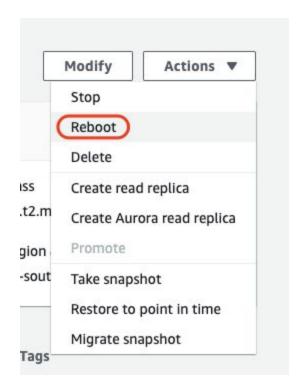
#### 然后更新RDS实例,采用新的参数组。



更新完参数组后,实例信息会提醒需要实例重启后才能生效。

Configuration	Instance class	Storage
DB instance id rds-sin-1	Instance class db.t2.micro	Encryption Not Enabled
Engine version 5.7.22	vCPU	Storage type General Purpose (SSD)
DB name -	RAM 1 GB	IOPS
License model General Public License	Availability  Master username	Storage 20 GiB
Option groups default:mysql-5-7	admin  IAM db authentication  Not Enabled  Multi AZ	Storage autoscaling Enabled Maximum storage threshold 1000 GiB
ARN arn:aws:rds:ap-southeast- 1:881826878679:db:rds-sin-1		
Resource id db- B64CVTJWCGCPTIVR4HH5D5RIDI	No Secondary Zone	
Created time Tue Mar 10 2020 10:39:18 GMT+0800 (China Standard Time)		
Parameter group db-param-group-for-gcp-replica (pending-reboot)		

### 对实例进行重启。



重启后, 确认实例状态正常, 并且相关参数已经更新。

```
SHOW GLOBAL VARIABLES LIKE 'gtid_mode';
```

#### 正确返回:

Variable_name	Value
gtid_mode	ON

确认enforce\_gtid\_consistency:

```
SHOW GLOBAL VARIABLES LIKE 'enforce_gtid_consistency';
```

#### 正确返回:

Variable_name	Value
enforce_gtid_consistency	ON

用下面命令创建用于同步和复制数据的数据库用户。

```
CREATE USER 'repl'@'%' IDENTIFIED BY 'Replicate4gcp';
GRANT REPLICATION SLAVE ON *.* TO 'repl'@'%';
GRANT SELECT, SHOW VIEW, RELOAD, REPLICATION CLIENT, EVENT, TRIGGER ON *.* TO 'repl'@'%';
```

## 创建同步复制数据库实例

首先创建谷歌云对象存储桶,用来上传存量数据的导出。可以在谷歌云控制台创建一个存储桶,选择与BigQuery数据集相同的区域,比如香港,并命名为youzhi-lab(此名为示例)。

导出数据库存量数据。本例的guestbook数据库为一个只有一个表的示例数据库。可以在谷歌云内的虚机,或者Cloud Shell上执行。

#### mysqldump \

-h rds-sin-1.cdmhzspt0jdq.ap-southeast-1.rds.amazonaws.com \

- -P 3306 -u repl -p \
- --databases guestbook \
- --hex-blob --skip-triggers \
- --order-by-primary --no-autocommit \
- --default-character-set=utf8mb4 \
- --single-transaction --set-gtid-purged=on | gzip > entries\_dump.sql.gz

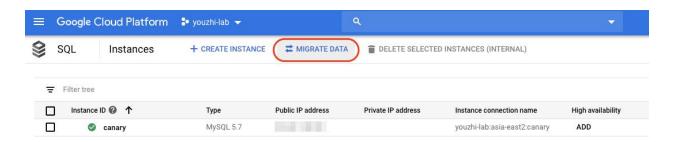
生成的导出文件可以在控制台上传到存储桶youzhi-lab,也可以执行下面命令。

### gsutil cp entries\_dump.sql.gz gs://[YOUR\_BUCKET]/

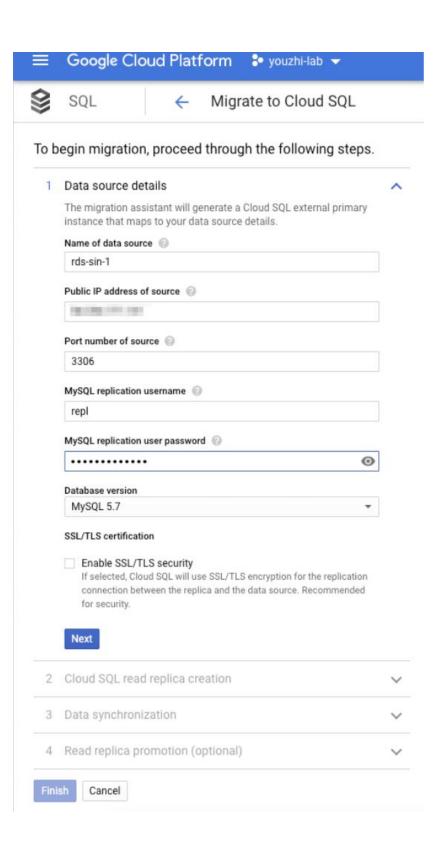
另外,如果RDS实例Binlog保存时间很短,可以在RDS实例执行下面命令,让其保存至少24小时。

call mysql.rds\_set\_configuration('binlog retention hours', 24);

在谷歌云Cloud SQL控制台,开始创建指向外部源数据库的同步副本。首先点击MIGRATE DATA 打开创建向导。



填写副本的基本信息。注意选择MySQL版本为5.7。区域与BigQuery数据集所在的区域一致。 SQL Dump File选择上面步骤上传在存储桶的文件。





SQL



Migrate to Cloud SQL

#### Read replica instance ID

Cannot be changed later. Use lowercase letters, numbers, and hyphens. Start with a letter.

rds-sin-1-cloudsql-replica



For better performance, keep your data close to the services that need it.

Region Zone Choice is permanent Can be changed at any time Any

asia-east2

Machine type

Select a machine type for your read replica instance. For best results, select similar or higher specifications to your source database, instance, or machine



#### db-n1-standard-1

vCPUs Memory 3.75 GB 1

Change

Network throughput (MB/s) 250 of 2,000

#### Storage type

Choice is permanent.

#### SSD (Recommended)

Most popular choice. Lower latency than HDD with higher QPS and

Lower performance than SSD with lower storage rates.

#### Storage capacity

10 - 30720 GB. Higher capacity improves performance, up to the limits set by the machine type. Capacity can't be decreased later.

10 GB

#### Enable automatic storage increases

If enabled, whenever you're nearing capacity, storage will be incrementally (and permanently) increased. Learn more

#### Import SQL dump from Google Cloud Storage

Choose the SQL file to import into your read replica that will seed your instance

SQL Dump File @

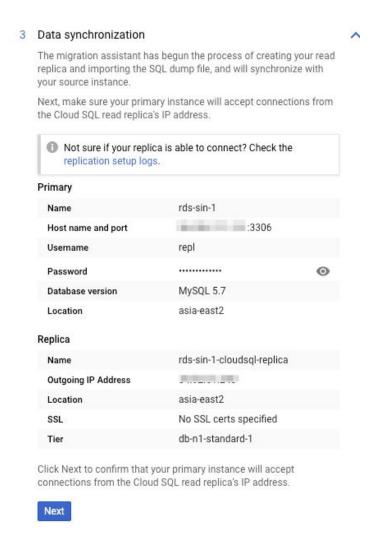


youzhi-lab/entries\_dump.sql.gz

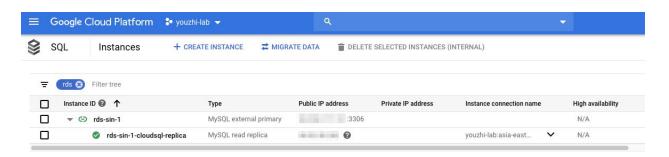
Once you select the SQL file, a Cloud SQL service account will receive readonly access to your Cloud Storage file and the bucket that contains it. Your bucket and file permissions will reflect this access.

Create

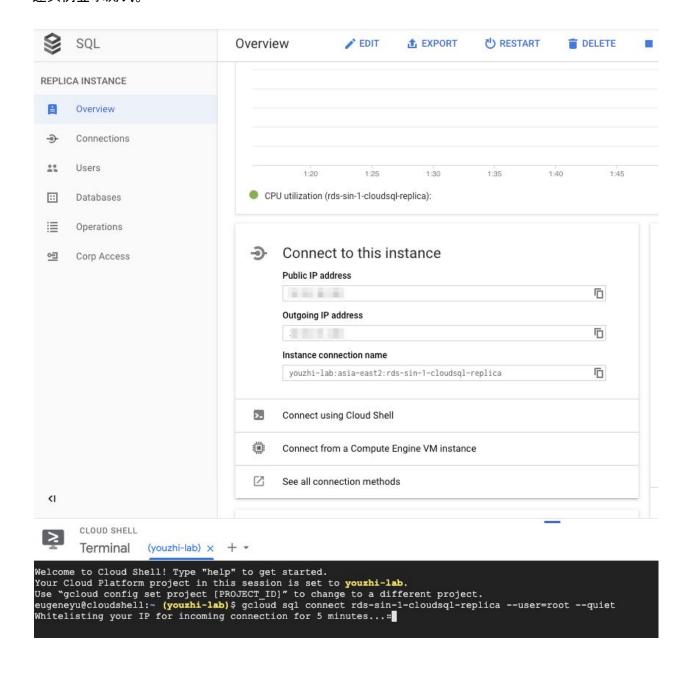
最后点击Finish按钮。等待一段时间可以看到副本创建成功。界面上可以看到实例的连接参数和 状态。



如果实例加载数据成功,在Cloud SQL实例列表里应该有绿色图标前缀。



在实例概况界面,选择Connect using Cloud Shell,可以在下部展开Cloud Shell命令行,进行快速实例登录测试。



当Cloud Shell中提示要求输入root的密码时,输入回车,因为root用户初始密码为空。登录数据库后,执行SQL命令,确认可以看到从RDS实例导入的数据。

```
affiliates. Other names may be trademarks of their respective
owners.
Type 'help;' or '\h' for help. Type '\c' to clear the current input statement.
mysql> SHOW DATABASES;
| Database
| information schema |
| guestbook
| mysql
| performance_schema |
| sys
5 rows in set (0.02 sec)
mysql> USE guestbook;
Reading table information for completion of table and column names
You can turn off this feature to get a quicker startup with -A
Database changed
mysql> SELECT * FROM entries;
| guestName | content | entryID |
+-----
| first guest | I got here! | 1 |
| second guest | Me too! |
2 rows in set (0.01 sec)
mysql>
```

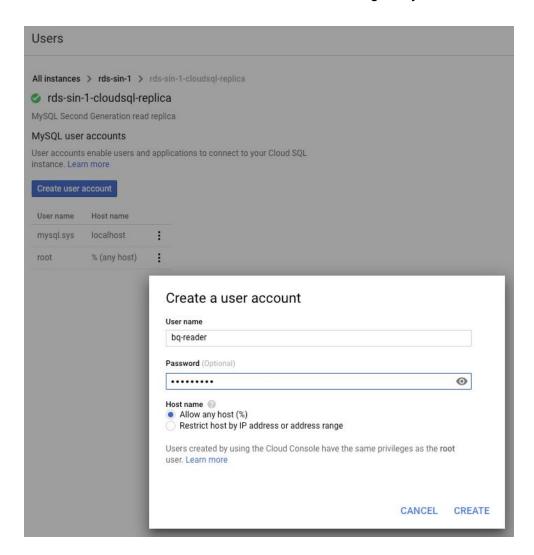
为了查看数据同步正常,可以回到RDS实例执行下面数据插入命令。

```
INSERT INTO entries (guestName, content) values ("Eugene", "Nice place!");
```

之后在Cloud Shell里与谷歌云数据库副本的会话中查询数据、确认新增数据同步成功。

## 在BigQuery中执行联合查询

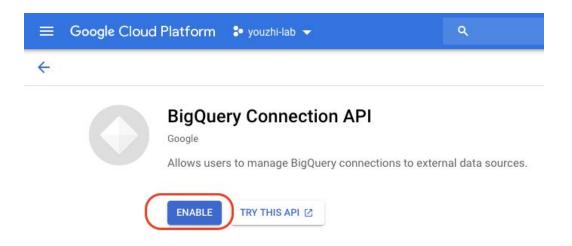
首先在Cloud SQL控制台给数据库副本创建一个代表BigQuery进行查询的用户。



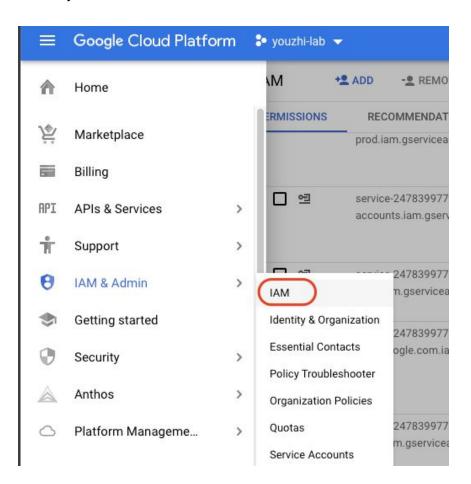
然后点击下面的链接,到谷歌云控制台API Dashboard里开启BigQuery Connection API。

### **BigQuery connection API**

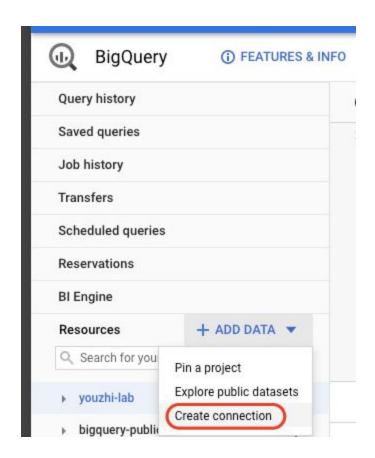
点击ENABLE按钮开启。等待几分钟开启完成。



确保你的控制台用户有bigquery.admin角色。如果没有,则到IAM配置页面配置一下。如果已经是Project Owner则不需要配置。



现在需要给BigQuery创建一个指向Cloud SQL副本的连接。在BigQuery控制台,点击ADD DATA 里面的Create connection。

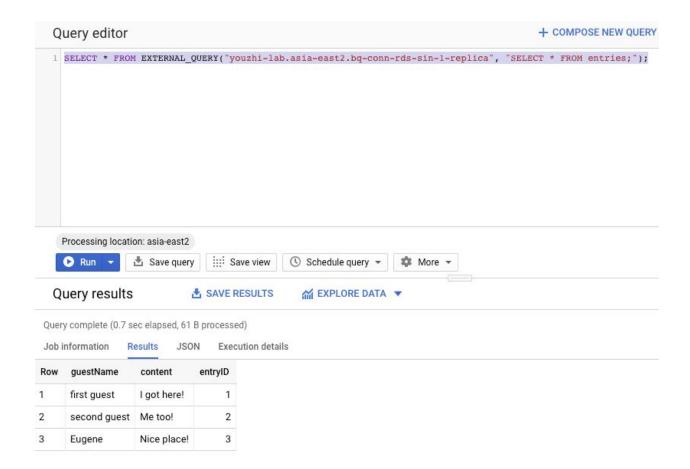


填写连接信息。选择与BigQuery数据集相同的区域。Cloud SQL Instance ID可以在数据库副本的详情页面获取。

## Create connection Connection type Cloud SQL - MySQL • Connection ID bq-conn-rds-sin-1-replica Connection location @ Hong Kong (asia-east2) Friendly name (Optional) Description (Optional) Cloud SQL instance ID 🔞 youzhi-lab:asia-east2:rds-sin-1-cloudsql-replica Database name guestbook Username bq-reader Password ..... Show password

连接建立好后,可以立即执行BigQuery查询,确认连接工作正常。可以在BigQuery的查询窗口执行类似下面指令的查询。

```
SELECT * FROM
EXTERNAL_QUERY("youzhi-lab.asia-east2.bq-conn-rds-sin-1-replica", "SELECT *
FROM entries;");
```



如果执行成功,返回正确数据,则说明连接工作正常。然后可以创建更复杂的查询,利用 BigQuery的强大功能合并查询不同来源的数据。一些示例可以参考附录[2]。

## 附录

- [1] Replicating from an external server (external master)
- [2] Cloud SQL federated queries